

곽민석 - 20183380

2023년 12월 13일 수요일

딥러닝

OOV 해결과 프롬프트를 적용한 LSTM

에세이 생성 모델 구현 및 평가

1. 프로젝트 개요

본 프로젝트에서는 LSTM을 이용하여 고등학생 수준의 에세이를 작문하는 모델을 만드는 것이다. 이 때, 현재 자연어 처리에서 사실상 표준인 transformer 계열에서 사용중인 BPE가 적용된 Tokenizer와 프롬프트 기법이 LSTM에서 어떠한 성능을 내고, 이의 효과를 알아보는것을 초점으로 두고 진행하였다.

2. 적용된 기술과 효과

기존에 교재에서 제공되는 예제에서는 Tokenizer를 일반 공백 단위로 처리하였다. 이는 문법이 한국어에 비해 단순한 영어에는 좋은 성능을 보여주나, 한국어의 경우 조사의 활용, 어미의 다양한 변화를 포괄하기에는 부족한 성능을 보여준다. 또한 단어가 Tokenizer에 없는 경우 OOV(Out of Vocabulary)가 발생하여 입력시 사용 가능한 단어가 제한된다. 이를 해결하기 위해 BPE(Byte Pair Encoding)가 적용된 Tokenizer를 이용하였다.

또한 모델이 작성해야하는 형식(수필, 주장문 등)과 주제를 아는 상태에서 글을 작성할 수 있도록 하기 위해 경량화된 프롬프트를 적용하였다. 이를 이용하여 모델이 주제를 이용하여 의미없는 문장이 아닌, 주제와 관련된 글을 작성하도록 학습시켰다.

3. Dataset

3.1.Feature of Raw Dataset

해당 프로젝트는 AIHub에서 제공하는 “에세이 글 평가 데이터”로, 총 133.30MB 크기의 데이터셋이다. 에세이를 작성한 연령대는 초등, 중등, 고등으로 나뉘며, 각 학년별로 나뉘어있다. 각각의 학생 분포는 다음과 같다.

학년	개수	비율	갯수
초등 4학년	5,827	38.187%	19,251
초등 5학년	6,761		
초등 6학년	6,663		
중등 1학년	6,955	39.262%	19,793
중등 2학년	6,649		
중등 3학년	6,189		
고등 1학년	4,812	22.552%	11,369
고등 2학년	4,800		

학년	개수	비율	갯수
고등 3학년		1,757	
평균		5,601.444	

Chart 1. 데이터 분포와 경향.

데이터셋의 각 학년별 에세이의 갯수는 위의 표와 같다. 여기서 이 데이터셋의 특징은 다음과 같다. 첫 번째로, 고등학생의 에세이 개체가 가장 적게 나타난다. 이는 중등부까지 약 38%에서 29%까지의 비율인것에 비해 상당히 적은 약 22.552% 만을 차지하고 있다. 두 번째로, 비율 뿐만 아니라 각 학년별 갯수에서도 다른 학년에 비해 적음을 보여주고 있다. 특히 고등학교 3학년이 고등학교 에세이 중에서도 가장 낮은 개체수를 보여주고 있다.

3.2.Filtering Dataset

해당 프로젝트에서는 고등학생 정도의 문장 실력의 에세이를 출력하기 위해 고등 1학년부터 3학년까지의 데이터를 따로 취합하여 사용하였다. 또한 5개의 세부 타입 중 책, 영화등 타 매체에 대한 주 내용을 알아야하는 설명글 타입은 제거한 후 사용하였다. 위의 필터링 과정을 통해 총 6,078개의 에세이를 이용하도록 설계하였다.

3.3.Light-weight Prompt

이번 프로젝트에서는 LSTM과 기본 Transformer에도 프롬프트가 가능한지 알아보는 실험을 진행하였다. 현재 사용되는 ChatGPT 혹은 GPT-3.5 Turbo 모델의 경우 다음과 같은 복잡한 프롬프트가 가능하다.

Create one quiz with 4 options. Follow the instructions below.

- The quiz must be about the movie currently exists in IMDb.
- There must be only 1 correct answer.

Prompt 1. 현재 GPT 3.5 이상에서 사용 가능한 프롬프트 예시.

위의 Prompt 1의 예시와 같이 정확히 어떤 규칙을 따라야 하는지 명시를 하면 이에 맞게 퀴즈를 내는 프롬프트이다. 하지만 본 과제에서는 모델의 Weight 크기가 GPT-3.5등과 비교했을 때 현저이 작은 크기의 모델을 이용하여 위와 같은 복잡한 프롬프트는 불가능할것으로 판단, 조금 더 작은 프롬프트를 제시하여 사용하였다.

본 과제에서는 Markup Language에서 사용하는 태그를 이용하여 구분자를 주는 방식으로 경량 프롬프트를 제안하였다. 대주제와 어떤 주제에 관한 글인지를 의미있는 태그를 지정하여 앞에

추가하고, 프롬프트가 끝난 경우 모델이 프롬프트가 끝나고 글을 추가해야 한다는것을 인지 시키도록 태그를 추가해주었다. 예시는 다음과 같다.

< type > 주장 < sub > 지적 재산권에 대한 본인의 생각 작성 < gen >

Prompt 2. 본 실험에서 제안하는 경량 프롬프트.

<type> 태그를 통해 어떤 종류의 글을 작성해야하는지 알고, <sub> 태그를 통해 어떤 주제를 글감으로 이용할것인지 알게된 후 마지막으로 <gen> 태그를 통해 모델이 글 작성을 시작하도록 하였다.

3.4.Data Feeding

학습 시 데이터를 모델에 제공할 때 LSTM의 경우 모든 데이터셋을 하나의 String으로 모아 학습시켜야 하는 상황이었다. 따라서 위의 프롬프트를 이용하여 하나의 에세이 데이터셋을 모아 하나의 String으로 만들어야 했다. 여기서 별다른 처리 없이 모든 개별 에세이 데이터를 붙이게 되면, 구분이 불가능할것으로 판단하여 개별 에세이 데이터마다 시작과 끝에 특수한 태그를 넣어주었다. 이를 적용한 예시는 다음과 같다.

[CLS] < type > 주장 < sub > 지적 재산권에 대한 본인의 생각 작성 < gen > 저는 지적재산권의 공유의 의무화에대해 찬성하는 바입니다. ... [생략] ... 저는 지적재산권의 공유의 의무화에대해 찬성하는 바입니다. [SEP]

Dataset 1. 데이터셋 구분자가 적용된 개별 데이터셋 예시.

위와 같은 형식으로 개별 에세이 데이터가 시작함을 알리는 [CLS]와 끝나게 되는 [SEP]를 두어 한 String으로 붙여도 개별 데이터셋이 구분되도록 하였다.

4. Tokenizer

LSTM과 Transformer는 학습을 위해 문자열을 tokenizing을 통해 숫자로 바꾸어 입력해야한다. 이때 학습 전 고려한 방법으로 크게 두 가지가 있었다. 첫 번째는 형태소 분석기를 이용하여 데이터셋 전체의 형태소를 분석하여 학습에 필요한 Corpus 그룹을 만드는것이다. 이 방법은 모델에서 학습할 단어를 제한하여 더 빠른 학습이 될 수 있다. 하지만, 입력 시 모델이 알지 못하는 단어를 입력하게 되는 경우 OOV(Out of Vocabulary)가 발생하여 추론이 불가능해진다. 두 번째 방법은 OOV가 해결된 Tokenizer를 이용하는 방법이다. Tokenizer에서는 공백과 형태소 분석을 이용하여 단어를 인식하는것이 아닌 BPE(Byte Pair Encoding)을 적용하여 자주 등장하는 단어는 하나의 단어로, 자주 등장하지 않는 단어는 개별 문자의 조합으로 변환되도록하여 OOV를 해결하였다.

예시로 “아버지가 방에 들어가신다. “와 같이 일반적으로 잘 사용되는 단어를 Tokenizer를 이용하여 tokenizing 하면 다음과 같이 나온다.

아버지 + ##가 + 방 + ##에 + 들어가 + ##신다 + .

예시 1. 예시 문장의 Tokenizing 후 결과.

위의 예시 결과와 같이 실제로 자주 사용되는 단어는 단어별로 나뉘어 tokenizing이 된다. 또한 뒤에 ##으로 토큰이 된 경우 붙여쓰고, 아닌 경우 띄어지는 것으로 인식이 된다.

만약 “우리들에게 봄은 시나브로 찾아온다.”와 같은 문장이 있을 때 만약, 형태소 분석기를 이용한 Tokenizer 구성 시 시나브로라는 단어가 없는 경우 입력으로 넣게 되었을 때 오류가 발생한다. 하지만 Tokenizer를 이용하게 되면 다음과 같이 tokenizing이 가능하다.

우리 + ##들 + ##에게 + 봄 + ##은 + 시 + ##나 + ##브로 + 찾아 + ## 온다 + .

예시 2. Vocab이 없는 문장의 Tokenizing 후 결과.

위의 예시 2와 같이 기존에 없는 단어도 조각으로 나누어 입력이 가능하여, 최소한 어떠한 단어인지 입력이 되지 않아 추론이 불가능한 경우를 막을 수 있다.

이러한 Tokenizer의 장점으로 인하여 이번 프로젝트에서는 해당 Tokenizer를 사용하였다.

5. Model

이번 과제에서는 사이토 코키의 “밑바닥부터 시작하는 딥러닝 2”에서 제공되는 Numpy를 이용한 LSTM 모델을 기반으로 제작하였다.

본 과제에서는 Tokenizer를 이용하여 문장을 분석하여 총 32,000개의 입력 단어가 가능하다. 이는 예제에서 제공하는 단어 10,000개의 3배 이상이 되는 수치로 단어 갯수 증가에 따른 Hidden Size와 Word vector의 크기 조절이 필요로 하였다. 실제 학습 시 기존 650개의 Hidden Size보다 1,024개로 증강하였을 때 퍼플렉서티가 약 20 낮게 나와 더 좋은 성능을 보여주었다. 이 결과를 토대로 Hidden Size와 Word Vector를 증강하여 학습 시켰다.

이를 결합하여 모델의 구조를 도식화하면 다음과 같다.




Fig 1. 생성 모델의 단위 LSTM 모델.

위의 방식과 같이 단어가 Embedding으로 들어오게 되면 이 정보를 Dropout을 통해 일부 제거 후 LSTM으로 계산을 한 후 이 작업을 한번 더 반복한 후에 Affine을 통해 토큰을 생성하도록 설계하였다.

6. Training

기존 제공 코드에서는 Optimizer를 SGD를 사용하였으나, 대부분의 학습에서 좋은 성능을 보여준 Adam(Adaptive Moment Estimation)으로 변경하였다.

학습은 총 5 epoch로 설정하였으나 실제로는 3 epoch를 실행하였다. 실제 학습 시 2 epoch에서 3 epoch로 진입한 이후 극적인 학습이 이루어지지 않아 학습을 조기 종료하는 Early Stop을 시행하였다.

마지막으로 학습이 진행될수록 기울기 소실이 발생할것을 염두하여 Gradient clipping을 적용시켜 학습을 안정화하였다.


그밖의 파라미터 설정은 다음과 같은 값으로 설정 후 학습하였다.

항목	값	항목	값
Batch Size	20	Learning Rate	20
Time Size	60	Max Epoch	5
Actual Epoch	3		

Chart 2. 학습 파라미터 항목 및 설정 값.

7. Result

본 과제에서 고안한 데이터와 모델을 이용하여 학습한 결과 다음의 그래프와 같은 결과가 나온다.



위의 그래프는 모델이 학습 진행에서 비교를 위해 앞 부분을 자른 나머지 부분에 대해 3 epoch가 진행되는 동안의 Perplexity 그래프이다. 첫 Perplexity는 31000에서, 마지막에는 49.22로 마치게 되었다. 녹색 그래프는 실제 데이터(파란색)의 경향성 파악을 위해 Log 그래프를 보조선으로 추가하였다.

학습이 완료된 해당 모델을 이용하여 에세이를 생성하게 하면 다음과 같은 결과가 나오게 된다.

[CLS]<type>주장<sub>혐오시설 건설문제에 대한 본인의 생각<gen>

입력 1. 혐오시설에 대한 주제 전달 프롬프트.

기장의 도시인에는 주민과 분장에 빠져 큰 진료가 합리적으로 들어온 것이다. 이런 언론의 지정으로 인해 작년에는 '신광부'였어지지만 센터백자들이 시작되는 것이고 후쿠시마의 환경이 가속화 되는 것은 빈번히 언급한 바 있다. 이러한 일들을 해결하기 위해서는 혐오시설을 지역에 설치하여 주시는 다른 지자체와 마을 주민들에게 찬성하는 경우가 많다.

출력 1. 혐오시설에 대한 모델의 에세이.

위의 입력 1과 출력 1에서는 혐오시설 건설문제에 대한 본인의 생각을 모델이 작성하도록 하고 이에 대한 모델의 결과를 표시하였다. 에세이에서 기장이 언급되는데, 이는 고리 원자력 발전소가 기장군에 위치하여 혐오시설 중 핵발전소에 관한 글임을 알수있다. 또한 이와 관련된 후쿠시마를 언급하며, 시설 설치와 지자체, 주민들의 의견에 대해 작성하였다.

[CLS]<type>주장<sub>지적 재산권에 대한 본인의 생각 작성<gen>

입력 2. 지적 재산권에 대한 주제 전달 프롬프트.

백신은 지적재산권의 의무화에 대해 제제를 강화해야 할 시기이다. 현재는 현재껏 최다국가 및 끊임없이 코로나19 감염 속도를 막는다. 종식 설득을 위해두고 많은 사람들이 백신을 접종할수록 더 열심히 세탁기 때돈을 반잡아야 하기 때문에 백신 접종에도 필요한 것들만 몰랐다. 인간은 어쩌면 평등하지 않는 의사밖에 없다. 하지만 백신 소개서씩 잃어버리는교사인 행사

출력 2. 지적 재산권에 대한 모델의 에세이.

입력 2와 출력 2에서는 지적 재산권에 대한 본인의 생각을 모델이 작성하도록 하고 이에 대한 모델의 결과를 표시하였다. 에세이에서는 백신과 코로나 19가 언급이 많이 되고 있다. 이는 해당 에세이 데이터가 수집된것이 대부분 코로나가 심하던 시기로, 학생들이 백신에 대해 저작권 완화를 통한 효과에 대해 다수가 작성하여 모델 또한 백신에 관련된 에세이를 작성하는것으로 추측된다.

[CLS]<type>주장<sub>개 식용 금지 입법에 관한 자신의 생각 작성<gen>

입력 3. 개 식용 금지 입법에 대한 주제 전달 프롬프트.

저는 그랬고 미국의 도운 일을 만들고 똑같은 명을 만들고 싶습니다. 저의 생각은 속상하고 천문의 빈도를 주는 것은 절대고시이지만 다같이일 올바른 언어가 아닌 것입니다. 어쩌면 내 주변에 수는 없는데 졸속라는 말을 가지고 냈다. 결국 사람들에게 외식업 정해졌고서야 홍보하지 않게 되면 전부라고 했다. 상상의 배를 가지고 두둘을 간지 쓰레기가

출력 3. 개 식용 금지 입법에 대한 모델의 에세이.

마지막으로, 입력 3와 출력 3에서는 개 식용 금지 입법에 대한 본인의 생각을 모델이 작성하도록 하고 이에 대한 모델의 결과를 표시하였다. 이 주제는 기존에 데이터셋에 들어있지 않는 주제로, 모델이 학습한 적이 없는 입력이다. 해당 모델은 에세이 외의 다른 데이터셋을 이용하여 학습되지 않아 주제와 관련 없는 문장을 출력하였다.

8. Conclusion and Proposer

8.1. Conclusion

위의 입력과 결과를 비교해본 결과 LSTM 모델에서 경량화된 프롬프트가 실제로 작동하는 것을 확인하였다. 다만, 이는 현재 사용되고 있는 프롬프트에 비해 아주 적은 조건이며 제한된 성능을 보여준다.

또한 입력 2, 출력 2번과 같이 데이터가 수집되던 당시의 배경을 반영하는 것을 토대로 보았을 때, 모델이 실제로 입력된 데이터들을 바탕으로 주제에 대한 경향성을 보여주는 것으로 파악되었다. 이러한 점은 모델이 입력 데이터에 따라 어떠한 정보에 대해 편향을 가질 수 있음으로 해석된다.

마지막으로, 입력 3, 출력 3과 같이 모델이 학습시 적용되지 않은 데이터와 단어에 대해서도 추론이 가능하였다. 이는 기본으로 제공된 코드에서는 불가능하였다. 다만, 학습된 적이 없는 주제로 올바른 출력이 나오지는 않았다.

8.2. Proposer

본 과제에서는 과제에서 기본 제공되는 에세이 데이터셋만을 이용하여 모델을 학습시켰다. 이러한 이유 때문인지, 모델이 접해보지 못한 주제에 대해서는 추론하지 못한 것이 조금 아쉬웠다. 이를 개선하기 위해 일반 글 데이터를 이용하여 글 생성에 대한 Base Model을 학습 시킨 후 에세이 데이터셋을 이용하여 Finetuning을 시켰다면 모델이 접해보지 않은 주제에 대해서도 작성이 가능하지 않을까 생각한다.

또한 이번 과제에서는 학습시 사용되는 파라미터에 대해 여러 변수로 실험해보지 않은 상황이다. 실제 모델을 제작할 때는 하이퍼 파라미터 튜닝을 이용하여 최적의 Learning Rate, Optimizer 등을 찾는 작업을 수행한다는 것을 과제 중 알게 되었다. 이를 바탕으로 본 과제의 모델에도 파라미터 튜닝을 적용하게 되었을 때 더 좋은 성능을 보여줄 것으로 기대한다.

8.3. Repository

<https://github.com/kms7530/EssayGPT>

Repository 주소입니다. Private Repository로, 아이디 ssuai, ys7yoo에 초대드렸습니다.

9. References

[1] [deep learning from scratch 2](#)

[2] [deep learning from scratch](#)

[3] [딥 러닝을 이용한 자연어 처리 입문](#)

[4] [Byte pair encoding 설명 \(BPE tokenizer, BPE 설명, BPE 예시\)](#)

[5] [ChatGPT 프롬프트 엔지니어링](#)

긴 글 읽어주셔서 감사합니다. 한 학기 동안 좋은 수업을 제공해주셔서 감사합니다.